NLP

Modelos secuenciales: RNNs

Dr. Rodrigo Cardenas Szigety
rodrigo.cardenas.sz@gmail.com

Timeline

1990: Celda RNN básica (Elman)
1997: LSTM

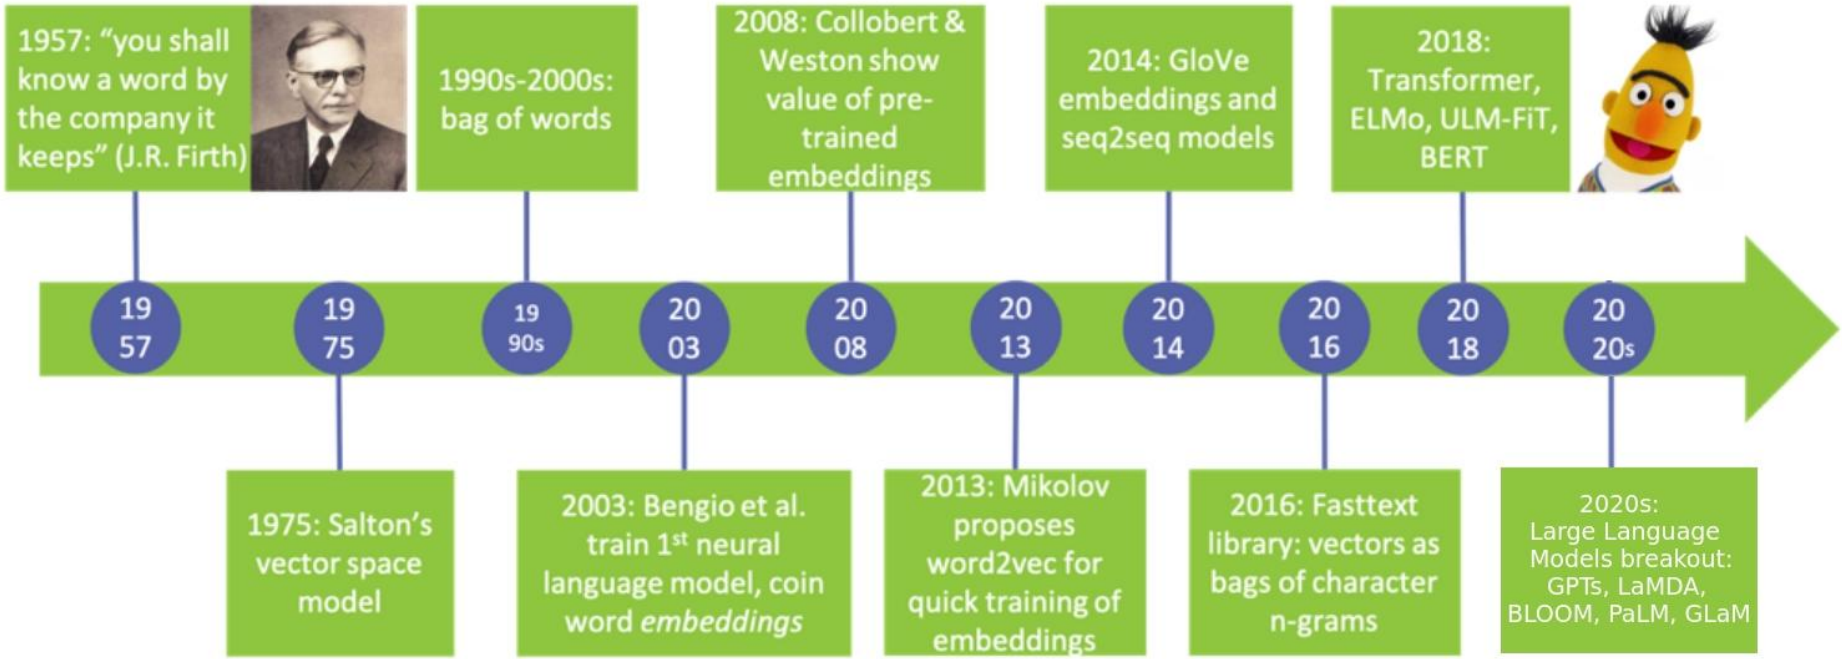

2016: LSTMs se convierten en SotA para traducción automática

Redes Neuronales Recurrentes (RNNs)

Es un tipo de neurona con un estado interno (o memoria) de manera que la información del pasado influye en los resultados futuros.

- Se utiliza principalmente para resolver problemas de secuencia, en donde el valor anterior está relacionado con el valor futuro.
- Permite construir modelos cuyos tamaños de secuencia sean potencialmente arbitrarios.
- Implementa modelos de lenguaje de la forma:

$$\prod_{i=1}^{i=m} P(w_i | w_{i-(n-1)}, \ldots, w_{i-1})$$

"Hoy el día está hermoso y despejado, se puede ver un hermoso cielo... azul"

Algunos problemas de secuencia

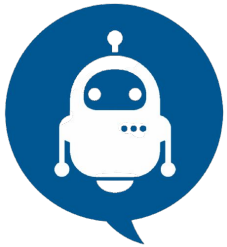

Bots Conversacionales

Name entity recognition

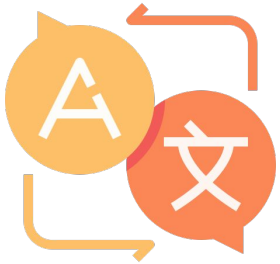

Traducción de idiomas

Speech to text

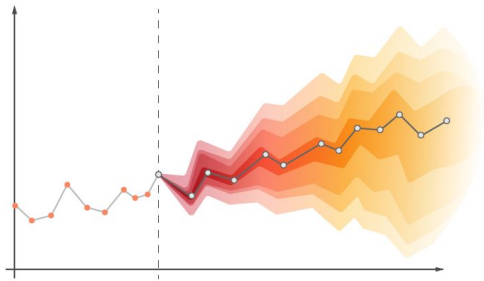

Series temporales

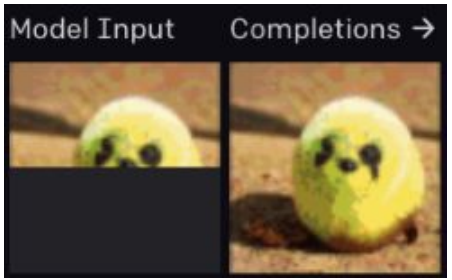

Completar una imagen

Celda RNN básica (Elman)

LINK API KERAS

En Keras: SimpleRNN

$$h_t = \sigma(W_{hh} * h_{t-1} + W_{hx} * x + b_h)$$
$$z_t = h_t$$

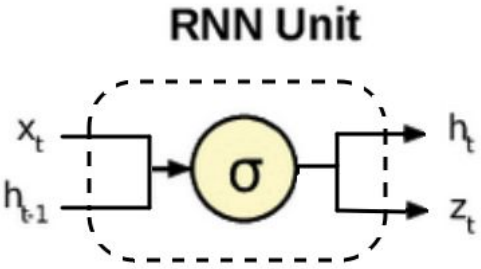

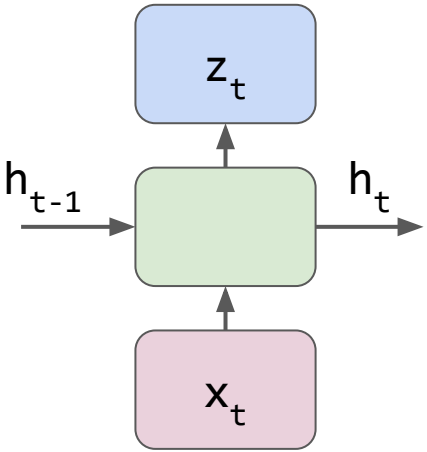

Unidad básica

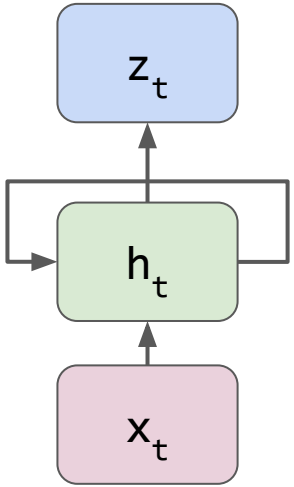

Representación compacta

Tipos de problemas de secuencia

LINK

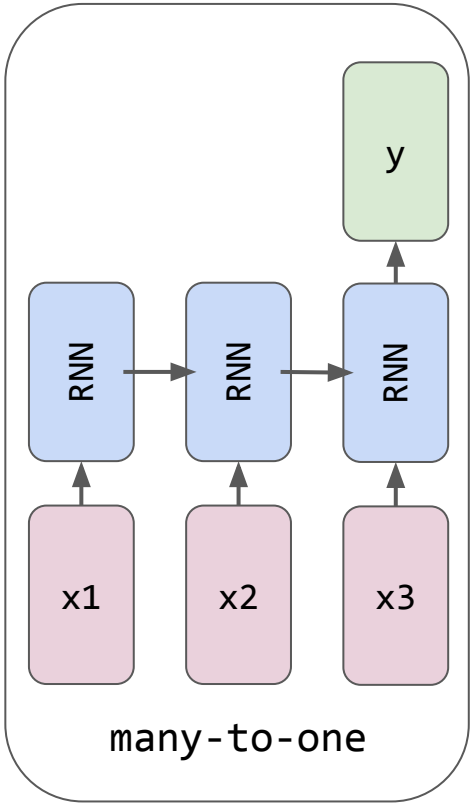

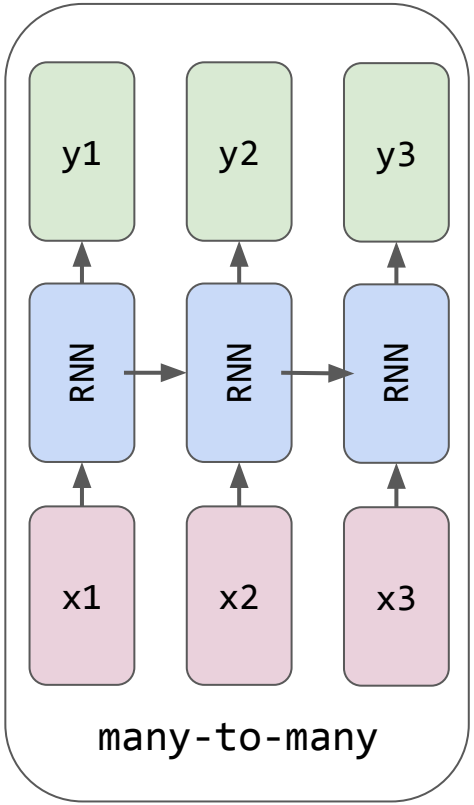

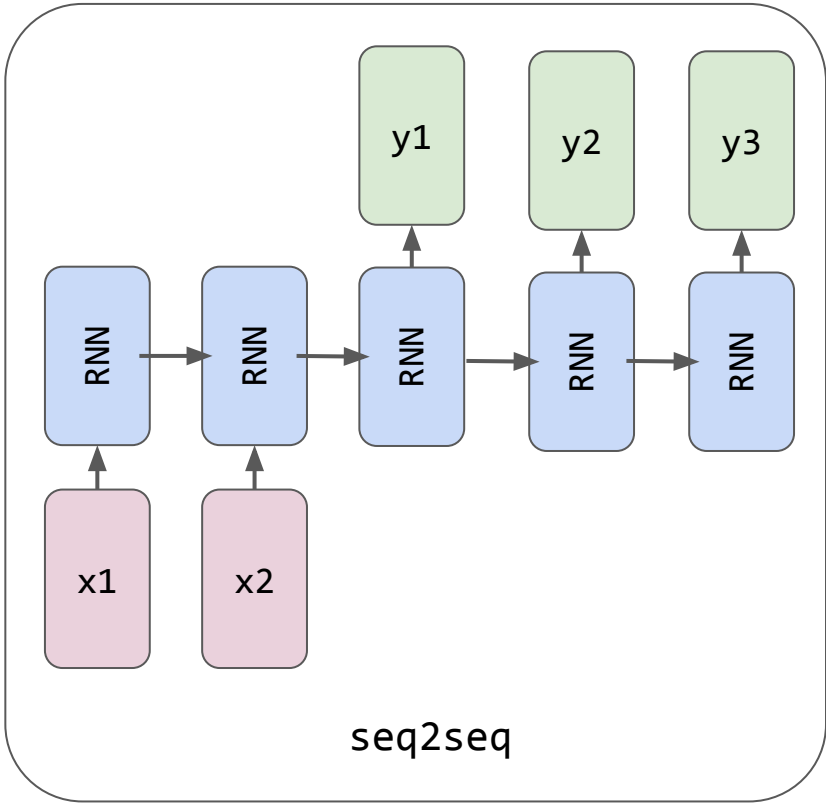

Grafo de cómputo de una RNN y BPTT (Backpropagation through time)

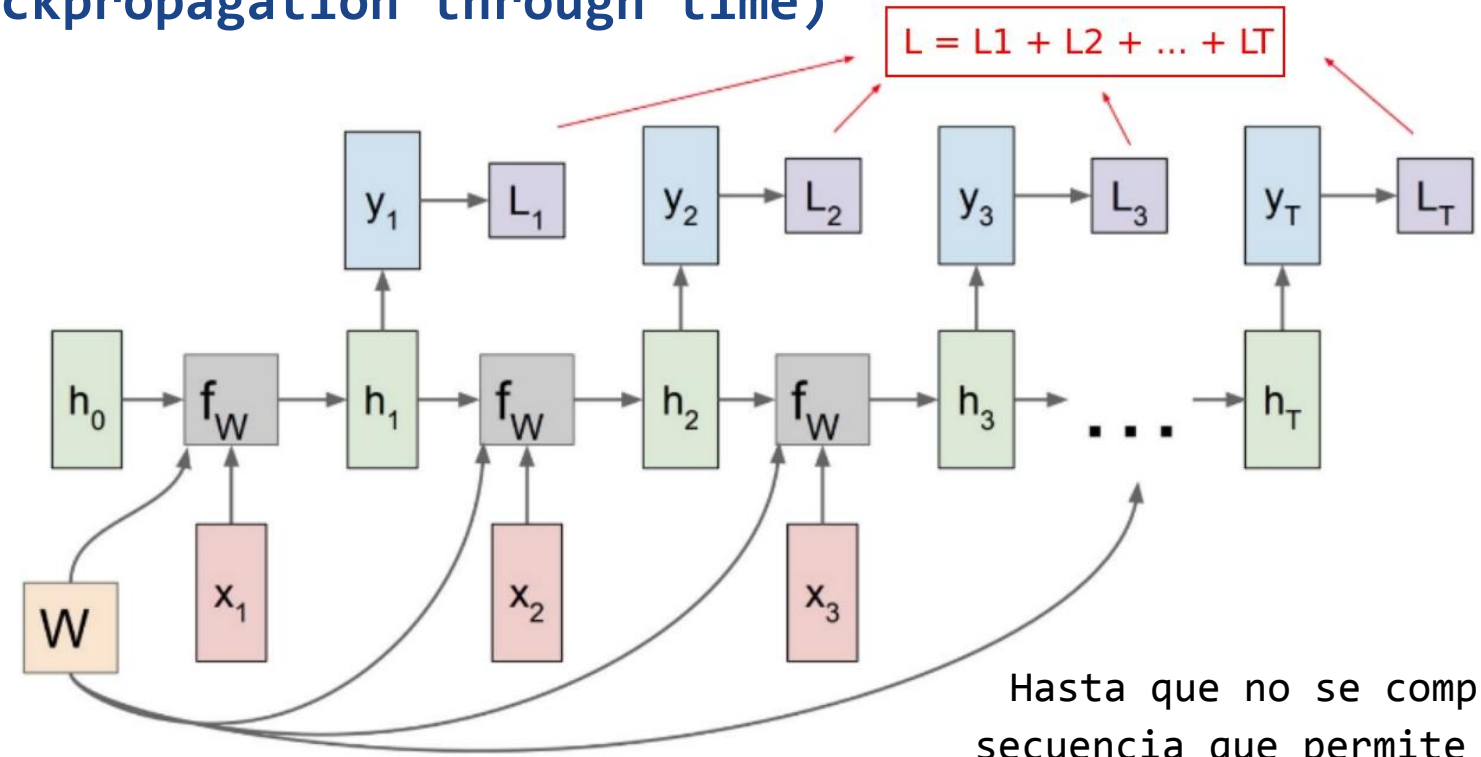

Hasta que no se complete la secuencia que permite calcular el loss no se actualizan los pesos (W) de la/s celda/s

Multi-layer RNN

Tal como se vio en los ejemplos se trata de apilar layers RNN en donde la salida de una se traslada a la entrada de la siguiente

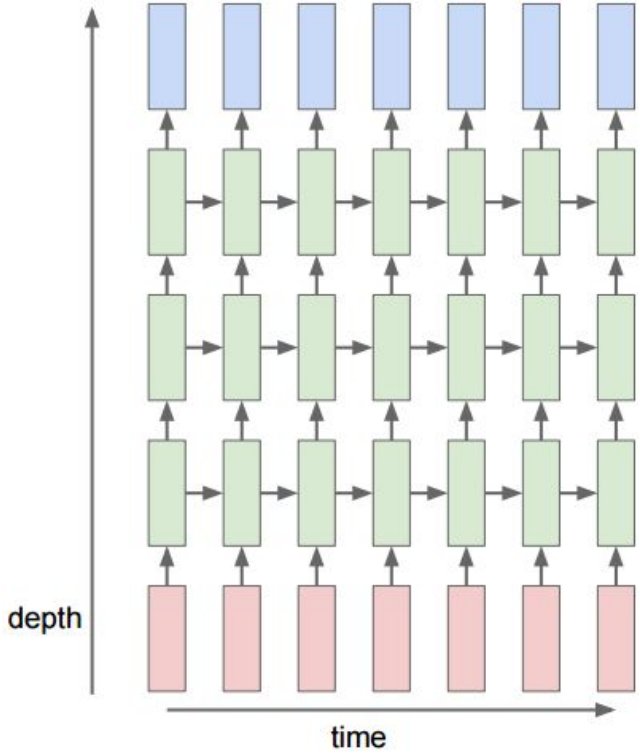

Problema de una RNN tradicional

LINK

"Una RNN tradicional solo usa información del pasado y no de las futuras palabras para predecir"

Ejemplo: Data una sentencia determinar si existe una entidad que represente al nombre de una persona utilizando (name entity recognition)

Ejemplo 1:
“Hoy escuche que Victoria terminó su bot para NLP” → persona

Ejemplo 2:
“Hoy escuche que Victoria cambió de intendente” → ciudad

La contextualización de la palabra es a futuro

Bidirectional RNN (BRNN)

BRNN PAPER

API KERAS

"La palabra anterior y la palabra futura tienen impacto en la presente predicción"

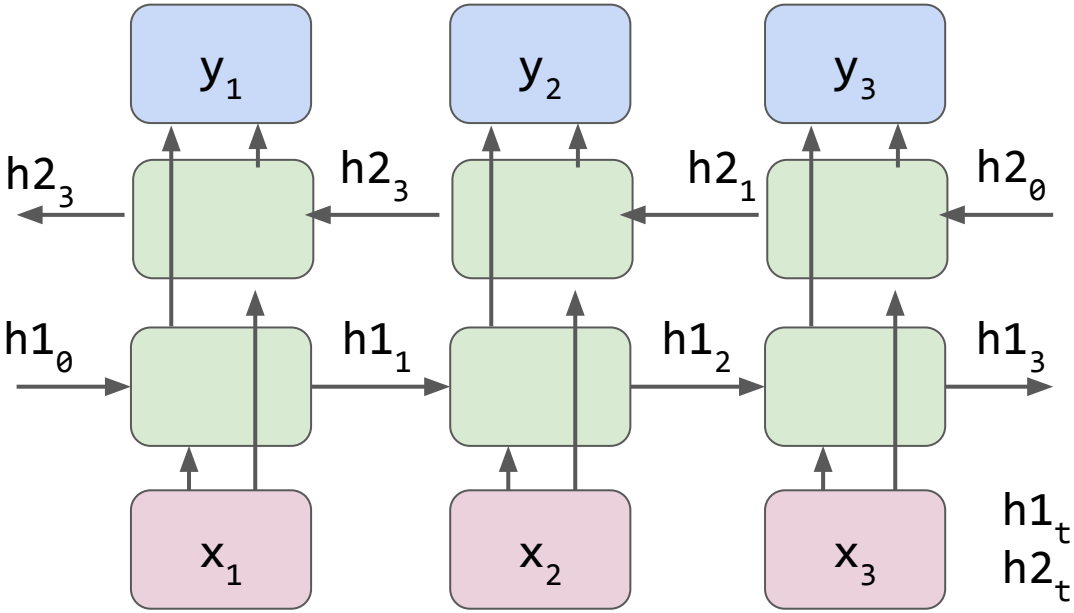

$$h1_t = \sigma(W_{hh1} * h1_{t-1} + W_{hx1} * x + b_1)$$
$$h2_t = \sigma(W_{hh2} * h2_{t+1} + W_{hx2} * x + b_2)$$

Las dos salidas pueden concatenarse, sumarse o promediarse

many-to-one

"Dada una sentencia o oración de entrada de tamaño fijo, el sistema arroja un único resultado que la representa".

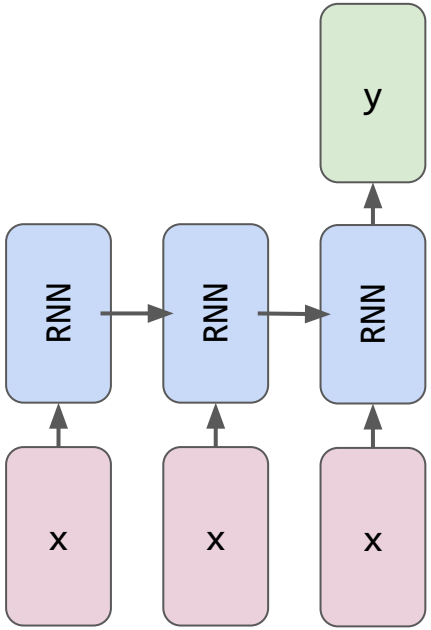

many-to-one

Este tipo de estructuras se utilizan para determinar cuál es la siguiente palabra o elemento en la secuencia o para clasificación (sentiment analysis).

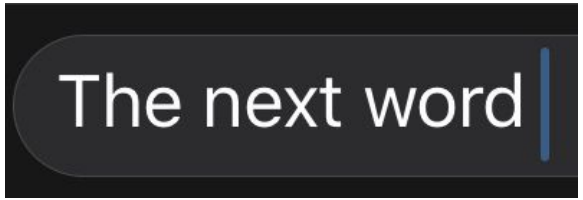

Predicción de próxima palabra

Análisis de sentimientos

many-to-one

Link al Colab

LINK

Long short term memory (LSTM) LINK

Se introduce este tipo de celda neuronal con mayor persistencia de memoria para lograr capturar relaciones de palabras a largo plazo.

Se crearon en 1997. Se adoptó como la layer principal para problemas de secuencia en 2014 hasta la aparición de los transformers en 2017.

Desplazaron completamente a las capas RNN simples (Elman), ya que el costo adicional de las LSTM es marginal respecto al beneficio que otorgan

Se basan en el principio de ponderar la importancia de una palabra respecto al contexto futuro/pasado (key words).

¿Comprarías este producto?

"Increible! El producto es lo que venden, hace lo que tiene que hacer y me ayudó mucho a resolver los problemas que tenía. Lo volvería a comprar sin dudas"

LSTM approach

LINK

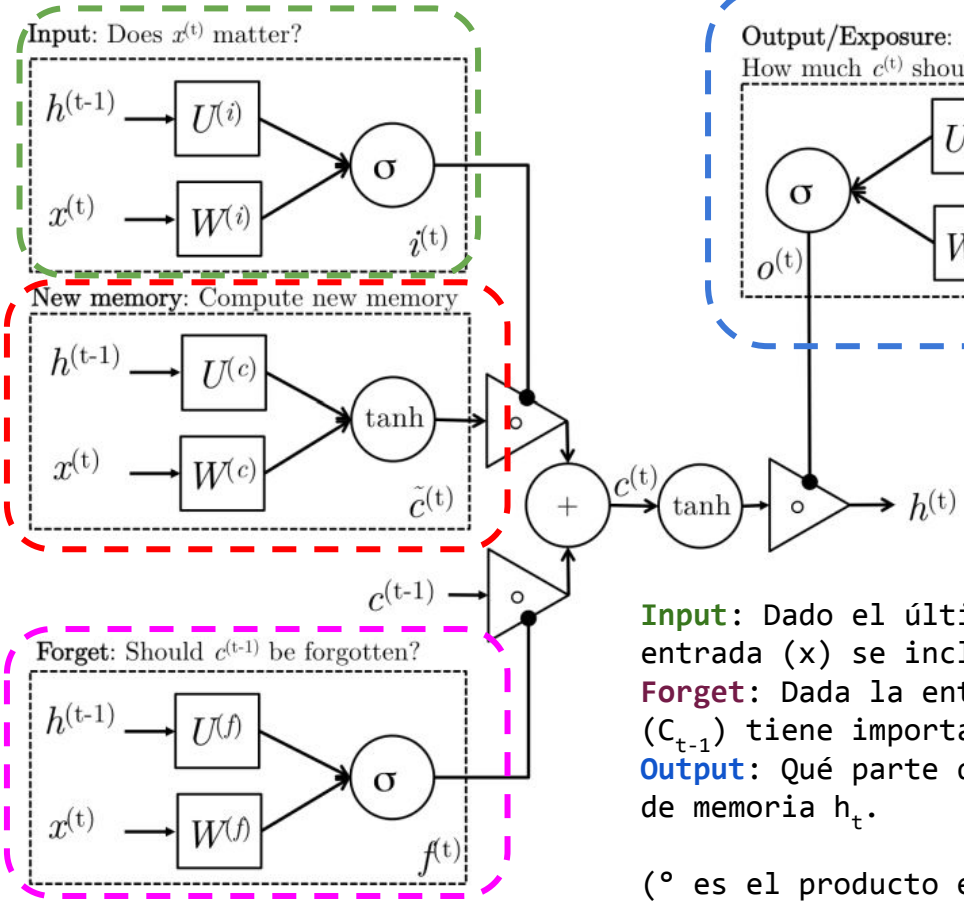

$$i_t = \sigma(W^{(i)}x_t + U^{(i)}h_{t-1})$$
$$f_t = \sigma(W^{(f)}x_t + U^{(f)}h_{t-1})$$
$$o_t = \sigma(W^{(o)}x_t + U^{(o)}h_{t-1})$$
$$\tilde{c}_t = \tanh(W^{(c)}x_t + U^{(c)}h_{t-1})$$
$$c_t = f_t \circ c_{t-1} + i_t \circ \tilde{c}_t$$
$$h_t = o_t \circ \tanh(c_t)$$

Input: Dado el último estado (h_{t-1}) evalúa cuánto de la nueva entrada (x) se incluirá en la memoria de largo plazo (C_t).
Forget: Dada la entrada (X) cuánto del estado de memoria anterior (C_{t-1}) tiene importancia en el nuevo estado.
Output: Qué parte del estado de memoria (C_t) pasa al próximo estado de memoria h_t.

(° es el producto elemento a elemento)

LSTM vs RNN

La memoria de largo plazo $\mathbf{c}_t$ permite propagar gradiente eficientemente a mayor “profundidad temporal”.

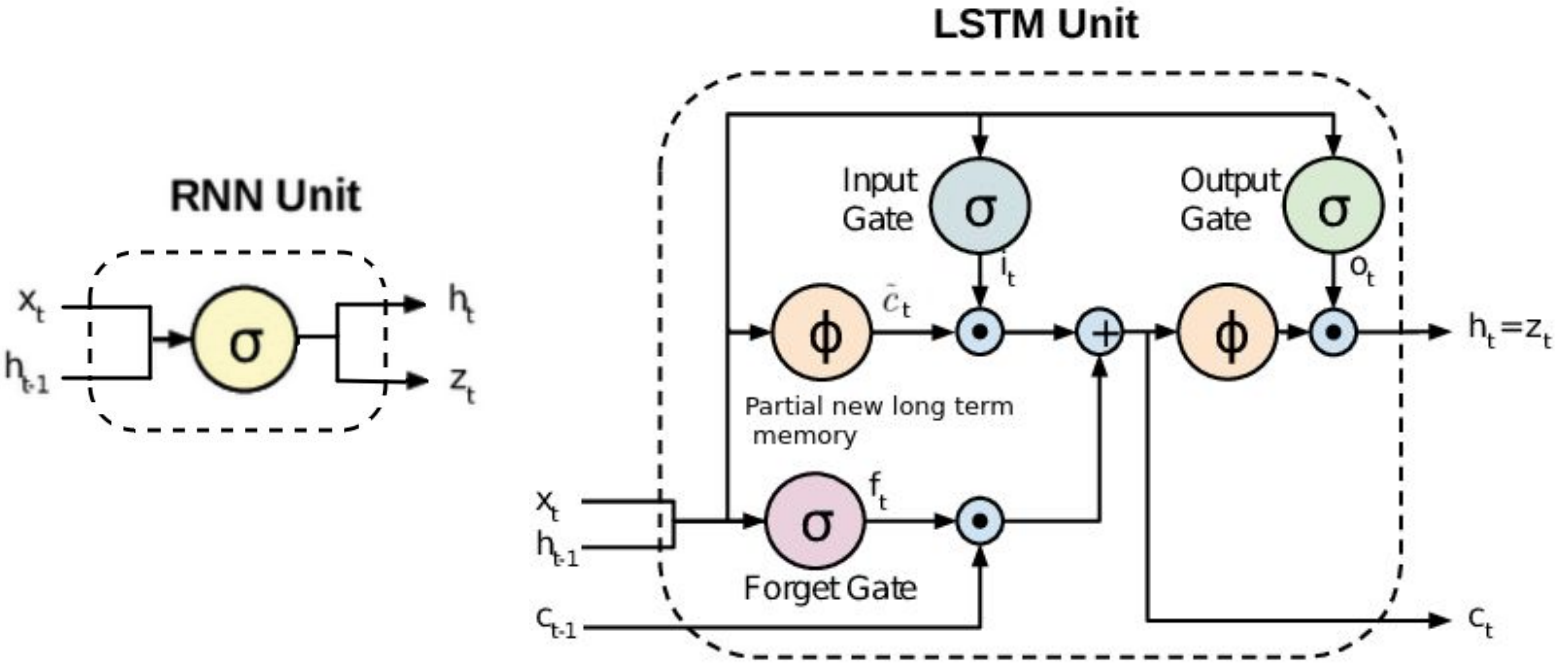

Gated Recurrent Units (GRU)

LINK

"Evolución de las RNN para superar problemas de “short-memory", versión reducida de una LSTM”.

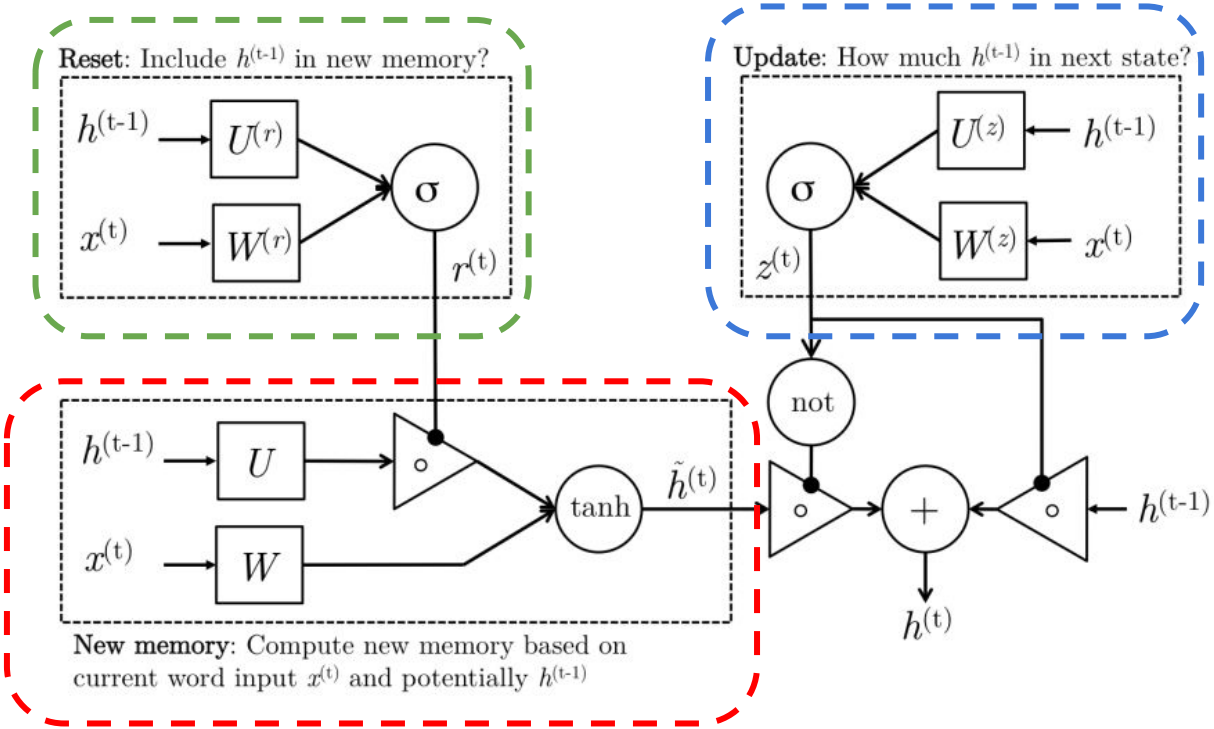

$$z_t = \sigma(W^{(z)}x_t + U^{(z)}h_{t-1})$$
$$r_t = \sigma(W^{(r)}x_t + U^{(r)}h_{t-1})$$
$$\tilde{h}_t = \tanh(r_t \circ Uh_{t-1} + Wx_t)$$
$$h_t = (1 - z_t) \circ \tilde{h}_t + z_t \circ h_{t-1}$$

(Update gate)

(Reset gate)

(New memory)

(Hidden state)

Gated Recurrent Units (GRU)

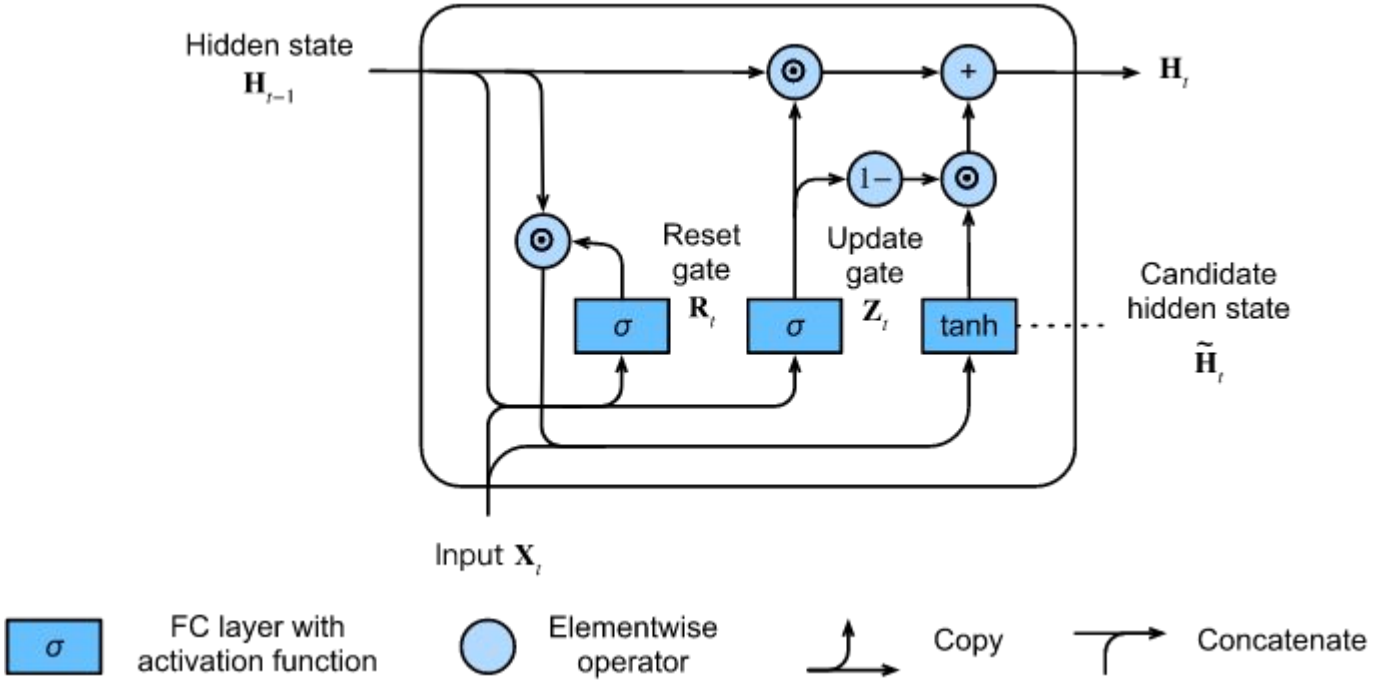

Text prediction

Link al Colab

LINK

Predicción de texto/modelos de lenguaje

Se utilizará many-to-one, por lo que hay que seleccionar la dimensión de la sentencia de entrada y dividir el texto en grupos:

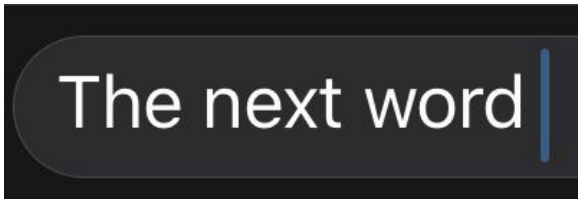

Predicción de próxima palabra

Sentencia

```
'Yesterday, all my troubles seemed so far away'
```

Tokens

```
['yesterday', 'all', 'my', 'troubles', 'seemed', 'so', 'far', 'away']
```

$$\prod_{i=1}^{i=m} P(w_i | w_{i-(n-1)}, \ldots, w_{i-1})$$

Vectores de entrada de 4 tokens

```
[['yesterday', 'all', 'my', 'troubles'],
 ['all', 'my', 'troubles', 'seemed'],
 ['my', 'troubles', 'seemed', 'so'],
 ['troubles', 'seemed', 'so', 'far']]
```

Midiendo desempeño en modelos de lenguaje: perplexity

$$\text{perplexity} = \prod_{t=1}^{T} \left(\frac{1}{P_{\text{LM}}(\boldsymbol{x}^{(t+1)} | \boldsymbol{x}^{(t)}, \ldots, \boldsymbol{x}^{(1)})} \right)^{1/T}$$

Normalized by number of words

Inverse probability of corpus, according to Language Model

Por cuestiones de estabilidad numérica conviene operar sobre los logaritmos de las probabilidades.

$$\text{PPL}(X) = \exp\left\{ -\frac{1}{t} \sum_{i}^{t} \log p_\theta(x_i | x_{<i}) \right\}$$

Modelo equiprobable: perplejidad V

Generación de texto en modelos de lenguaje: Greedy search

Medimos la verosimilitud de una secuencia

$$\prod_{i=1}^{i=m} P(w_i | w_{i-(n-1)}, \ldots, w_{i-1})$$

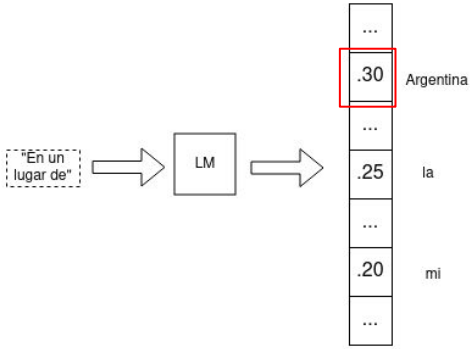

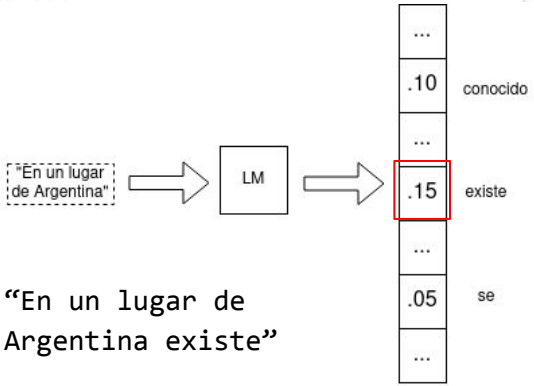

"En un lugar de Argentina existe"

.30 x .15 = .045

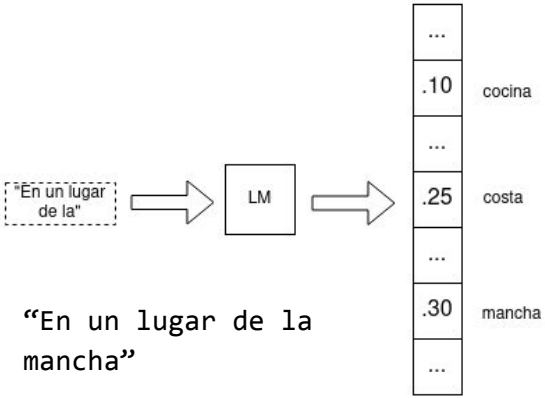

"En un lugar de la mancha"

.25 x .30 = .075

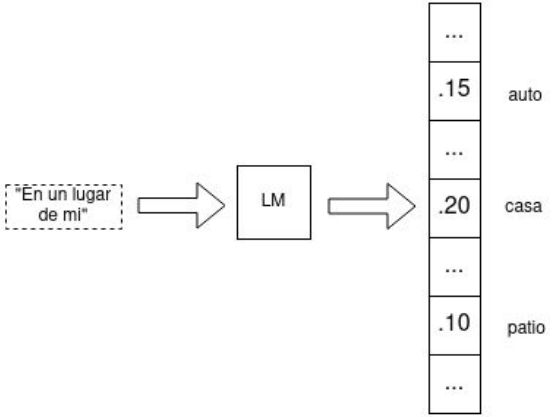

Generación de texto en modelos de lenguaje: Beam search

Ahora escogemos los mejores “beams” para seguir generando.

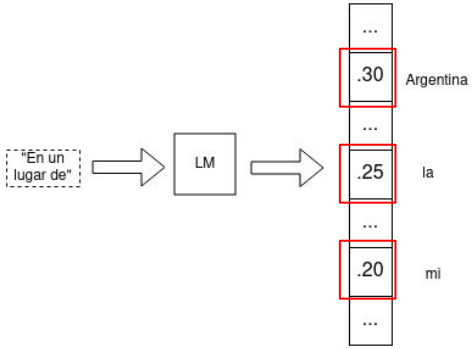

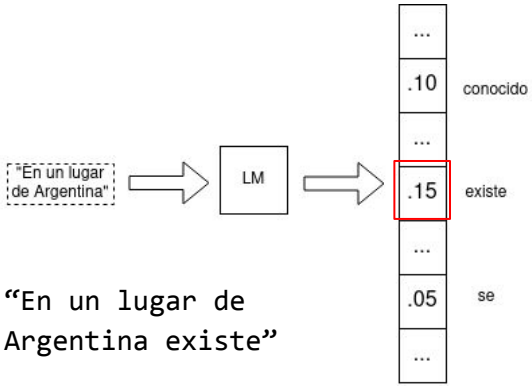

“En un lugar de Argentina existe”

.30 x .15 = .045

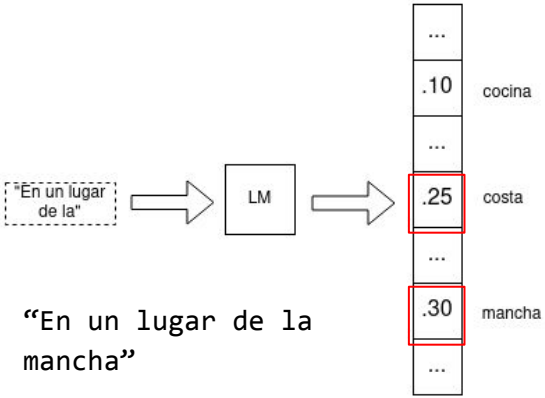

“En un lugar de la mancha”

.25 x .30 = .075

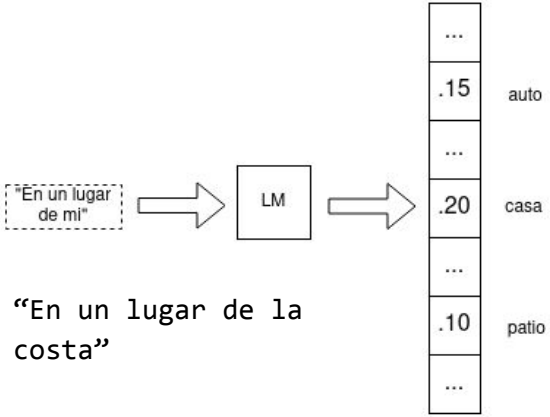

“En un lugar de la costa”

.25 x .25 = .0625

Generación de texto en modelos de lenguaje: Beam search

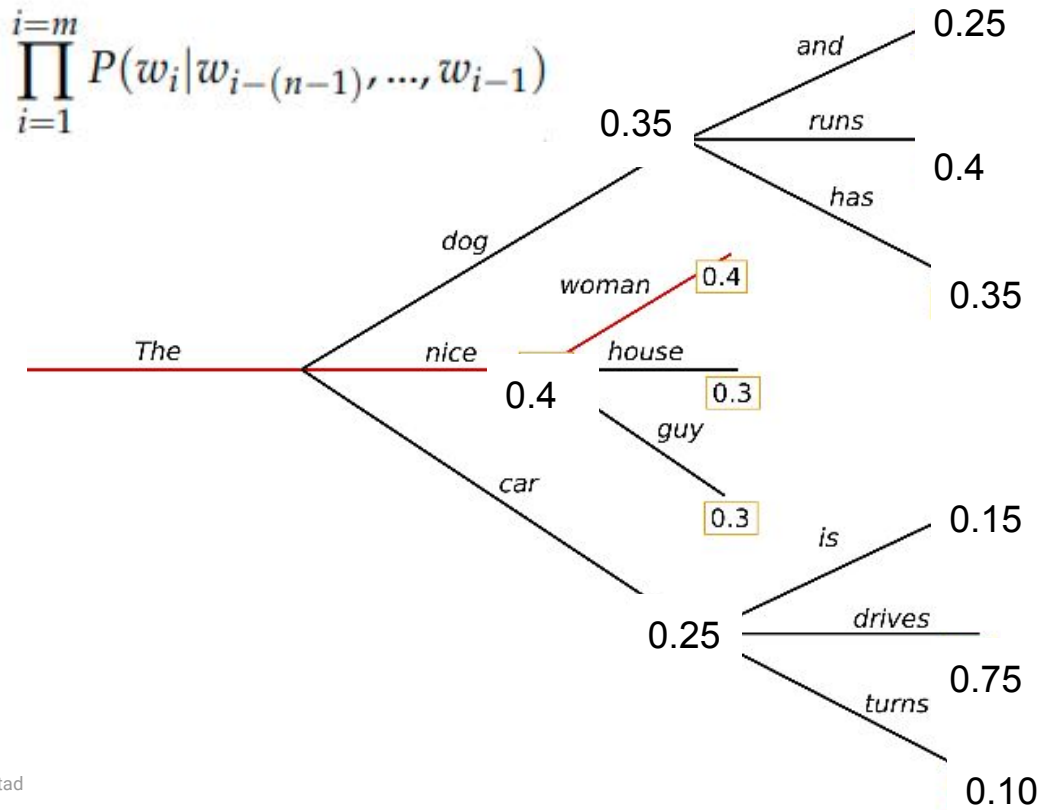

`num_beams=2`

Paso 1:
"The nice" → 0.4
"The dog" → 0.35

Paso 2:
"The nice woman" → 0.4x0.4 = 0.16
"The dog runs" → 0.35x0.4 = 0.14

Siempre encuentra una secuencia con prob >= que Greedy Search

Es un método heurístico. No asegura que encontrar la más probable. ("The car drives" = 0.175)

Generación de texto en modelos de lenguaje: Muestreo aleatorio con temperatura

$$P_i = \frac{e^{\frac{y_i}{T}}}{\sum_{k=1}^{n} e^{\frac{y_k}{T}}}$$

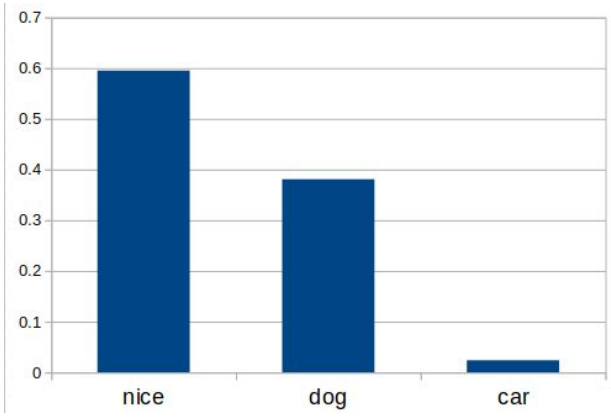

Temperatura = 0.5

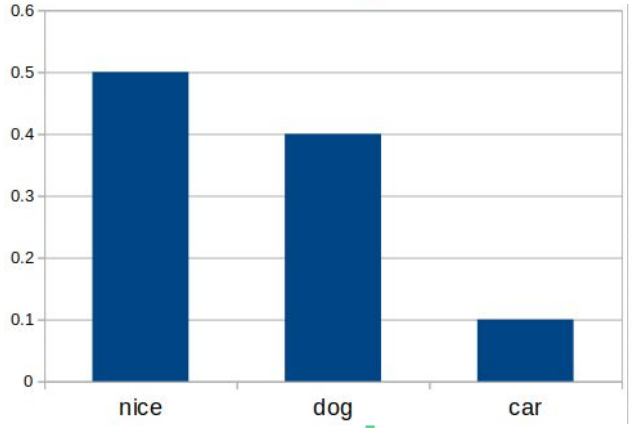

Temperatura = 1

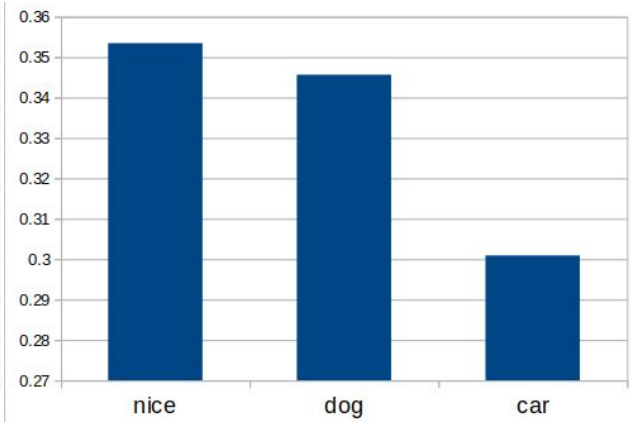

Temperatura = 10

Desafio

Utilizar otro dataset y poner en práctica la generación de secuencias con las estrategias presentadas.